图1　动机：decode 阶段受 HBM 带宽支配，KV 读流量是主因（RTX 4080 SUPER，真实测量+解析）



