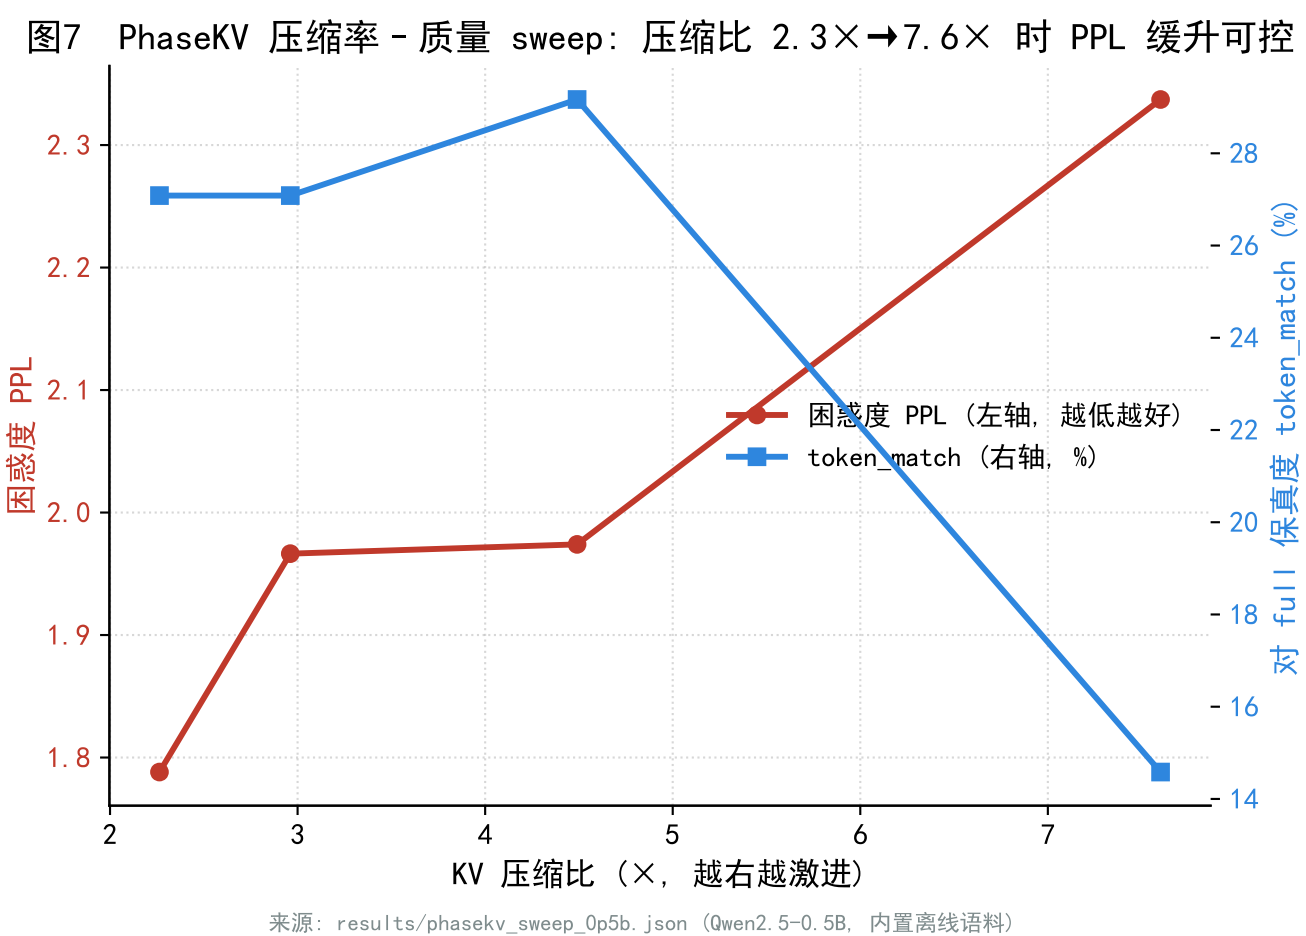
图7　PhaseKV 压缩率－质量 sweep：压缩比 2.3×→7.6× 时 PPL 缓升可控
困惑度 PPL
对 full 保真度 token_match（%）
困惑度 PPL（左轴，越低越好）
token_match（右轴，%）
KV 压缩比（×，越右越激进）
2.3
2.2
2.1
2.0
1.9
1.8
28
26
24
22
20
18
16
14
2
3
4
5
6
7
来源：results/phasekv_sweep_0p5b.json（Qwen2.5-0.5B，内置离线语料）